Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение высшего образования
«Московский государственный технический университет имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ _____” Информатика и системы управления”_____

КАФЕДРА _____”Системы обработки информации и управления”_____

РАСЧЕТНО-ПОЯСНИТЕЛЬНАЯ ЗАПИСКА

К КУРСОВОЙ РАБОТЕ

НА ТЕМУ:

_____*”Решение задачи регрессии”*_____

Студент _____ИУ5-62Б____ _____
_____**Н.А.Михеев**___
(Группа) (Подпись, дата) (И.О.Фамилия)

Руководитель курсовой работы _____ _____**Ю.Е. Гапанюк**__
(Подпись, дата) (И.О.Фамилия)

Консультант _____ _____**Ю.Е. Гапанюк**__
(Подпись, дата) (И.О.Фамилия)

2020 г.

Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Московский государственный технический университет имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

УТВЕРЖДАЮ
Заведующий кафедрой _____ИУ5___
(Индекс)
_____ В.М. Черненький
(И.О.Фамилия)
« _____ » _____ 20 ____ г.

З А Д А Н И Е
на выполнение курсовой работы

по дисциплине _____”Технологии машинного обучения”_____

Студент группы _____ИУ5-63Б_____

_____Михеев Никита Алексеевич__
(Фамилия, имя, отчество)

Тема курсовой работы ___”Решение задачи регрессии_____
_____
_____

Направленность КР (учебная, исследовательская, практическая, производственная, др.)
_____учебная_____
Источник тематики (кафедра, предприятие, НИР) _____

График выполнения работы: 25% к _3_ нед., 50% к _9_ нед., 75% к 12 нед., 100% к 16 нед.

Задание _Решение задачи машинного обучения. Результатом курсового проекта является отчет, содержащий описания моделей, тексты программ и результаты экспериментов. _____
_____
_____
_____
_____

Оформление курсовой работы:

Расчетно-пояснительная записка на _____ листах формата А4.

_____
_____
_____
_____

Дата выдачи задания « _7_ » __февраля__ 2020 г.

Руководитель курсовой работы _____ _____**Ю.Е. Гапанюк**___
(Подпись, дата) (И.О.Фамилия)

Студент _____ _____**Н.А.Михеев**____
(Подпись, дата) (И.О.Фамилия)

Примечание: Задание оформляется в двух экземплярах: один выдается студенту, второй хранится на кафедре.

Задание

1. Поиск и выбор набора данных для построения моделей машинного обучения. Построение модели машинного обучения и решение задачи регрессии.
2. Проведение разведочного анализа данных. Построение графиков, необходимых для понимания структуры данных. Анализ и заполнение пропусков в данных.
3. Выбор признаков, подходящих для построения моделей. Кодирование категориальных признаков Масштабирование данных. Формирование вспомогательных признаков, улучшающих качество моделей.
4. Проведение корреляционного анализа данных. Формирование промежуточных выводов о возможности построения моделей машинного обучения.
5. Выбор метрик для последующей оценки качества моделей.
6. Выбор наиболее подходящих моделей для решения задачи регрессии.
7. Построение базового решения (baseline) для выбранных моделей без подбора гиперпараметров. Производится обучение моделей на основе обучающей выборки и оценка качества моделей на основе тестовой выборки.
8. Подбор гиперпараметров для выбранных моделей.
9. Формирование выводов о качестве построенных моделей на основе выбранных метрик

Оглавление

Введение

Данная работа предназначена для усвоения и закрепления знаний по дисциплине «Технологии машинного обучения». Здесь закрепляются навыки проведения разведочного анализа данных, выбора признаков для построения модели, проведения корреляционного анализа, подбора метрик, решения задачи регрессии, построения базового решения и подбора гиперпараметров.

Основная часть

New York City Taxi Fare Prediction

Признаки

- **pickup_datetime** - время начала поездки
- **pickup_longitude** - координата долготы начала поездки
- **pickup_latitude** - координата широты начала поездки
- **dropoff_longitude** - координата долготы конца поездки
- **dropoff_latitude** - координата широты конца поездки
- **passenger_count** - число пассажиров

Целевой признак

- **fare_amount** - стоимость поездки

In [1]:
```
import pandas as pd
import numpy as np
import scipy

from sklearn.linear_model import LinearRegression
from sklearn.ensemble import RandomForestRegressor
import lightgbm
from sklearn.model_selection import GridSearchCV

import seaborn as sns
import matplotlib.pyplot as plt
import datetime as dt
from math import sqrt
from scipy.spatial import distance

%matplotlib inline
```

```
/usr/local/lib/python3.7/site-packages/lightgbm/__init__.py:46: UserWarning: Starting from version 2.2.1, the library file in d
istribution wheels for macOS is built by the Apple Clang (Xcode_8.3.1) compiler.
This means that in case of installing LightGBM from PyPI via the ``pip install lightgbm`` command, you don't need to install th
e gcc compiler anymore.
Instead of that, you need to install the OpenMP library, which is required for running LightGBM on the system with the Apple Cl
ang compiler.
You can install the OpenMP library by the following command: ``brew install libomp``.
  "You can install the OpenMP library by the following command: ``brew install libomp``.", UserWarning)
```

In [2]:
```
df = pd.read_csv('train.csv', nrows=1000)
```

In [3]:
```
df.shape
```

Out[3]:
```
(1000, 8)
```

In [4]:
```
df.head()
```

Out[4]:

	key	fare_amount	pickup_datetime	pickup_longitude	pickup_latitude	dropoff_longitude	dropoff_latitude	passenger_count
0	2009-06-15 17:26:21.0000001	4.5	2009-06-15 17:26:21 UTC	-73.844311	40.721319	-73.841610	40.712278	1
1	2010-01-05 16:52:16.0000002	16.9	2010-01-05 16:52:16 UTC	-74.016048	40.711303	-73.979268	40.782004	1
2	2011-08-18 00:35:00.00000049	5.7	2011-08-18 00:35:00 UTC	-73.982738	40.761270	-73.991242	40.750562	2
3	2012-04-21 04:30:42.0000001	7.7	2012-04-21 04:30:42 UTC	-73.987130	40.733143	-73.991567	40.758092	1
4	2010-03-09 07:51:00.000000135	5.3	2010-03-09 07:51:00 UTC	-73.968095	40.768008	-73.956655	40.783762	1

Предобработка

Время

- Парсинг времени
- Создание признака - расстояние между точками

In [5]:
```
df['pickup_datetime'] = pd.to_datetime(df['pickup_datetime'])
df['hour'] = df['pickup_datetime'].dt.hour
df['weekday'] = df['pickup_datetime'].dt.weekday.map({0 : 'Monday', 1: 'Tuesday', 2: 'Wednesday',
                                                      3: 'Thursday', 4: 'Friday', 5: 'Saturday', 6: 'Sunday'})
```

In [6]:
```
df
```

Out[6]:

	key	fare_amount	pickup_datetime	pickup_longitude	pickup_latitude	dropoff_longitude	dropoff_latitude	passenger_count	hour	wee
0	2009-06-15 17:26:21.0000001	4.5	2009-06-15 17:26:21	-73.844311	40.721319	-73.841610	40.712278	1	17	Mc
1	2010-01-05 16:52:16.0000002	16.9	2010-01-05 16:52:16	-74.016048	40.711303	-73.979268	40.782004	1	16	Tue
2	2011-08-18 00:35:00.00000049	5.7	2011-08-18 00:35:00	-73.982738	40.761270	-73.991242	40.750562	2	0	Thu
3	2012-04-21 04:30:42.0000001	7.7	2012-04-21 04:30:42	-73.987130	40.733143	-73.991567	40.758092	1	4	Sat
4	2010-03-09 07:51:00.000000135	5.3	2010-03-09 07:51:00	-73.968095	40.768008	-73.956655	40.783762	1	7	Tue
5	2011-01-06 09:50:45.0000002	12.1	2011-01-06 09:50:45	-74.000964	40.731630	-73.972892	40.758233	1	9	Thu
6	2012-11-20 20:35:00.0000001	7.5	2012-11-20 20:35:00	-73.980002	40.751662	-73.973802	40.764842	1	20	Tue

In [7]:
```
df['manhattan_distance'] = df.apply(lambda x:
    distance.cityblock([x['pickup_longitude'], x['pickup_latitude']], [x['dropoff_longitude'], x['dropoff_latitude']]), axis
```

In [8]:
```
df.head()
```

Out[8]:

	key	fare_amount	pickup_datetime	pickup_longitude	pickup_latitude	dropoff_longitude	dropoff_latitude	passenger_count	hour	weekday	
0	2009-06-15 17:26:21.0000001	4.5	2009-06-15 17:26:21	-73.844311	40.721319	-73.841610	40.712278	1	17	Monday	
1	2010-01-05 16:52:16.0000002	16.9	2010-01-05 16:52:16	-74.016048	40.711303	-73.979268	40.782004	1	16	Tuesday	
2	2011-08-18 00:35:00.00000049	5.7	2011-08-18 00:35:00	-73.982738	40.761270	-73.991242	40.750562	2	0	Thursday	
3	2012-04-21 04:30:42.0000001	7.7	2012-04-21 04:30:42	-73.987130	40.733143	-73.991567	40.758092	1	4	Saturday	
4	2010-03-09 07:51:00.000000135	5.3	2010-03-09 07:51:00	-73.968095	40.768008	-73.956655	40.783762	1	7	Tuesday	

In [9]:
```
df[df.isna().any(axis=1)]
```

Out[9]:

key	fare_amount	pickup_datetime	pickup_longitude	pickup_latitude	dropoff_longitude	dropoff_latitude	passenger_count	hour	weekday	manhattan_distar

In [10]:
```
df.drop(['key','pickup_datetime'], axis=1, inplace=True)
```

Графики распределения величин

Уберем выбросы, чтобы можно было смотреть на графики

In [11]:
```
tmp = df['weekday']
df.drop('weekday', axis=1, inplace=True)
```

In [12]:
```
df = df[(np.abs(scipy.stats.zscore(df)) < 3).all(axis=1)]
```

In [13]:
```
df
```

Out[13]:

	fare_amount	pickup_longitude	pickup_latitude	dropoff_longitude	dropoff_latitude	passenger_count	hour	manhattan_distance
0	4.50	-73.844311	40.721319	-73.841610	40.712278	1	17	0.011742
1	16.90	-74.016048	40.711303	-73.979268	40.782004	1	16	0.107481
2	5.70	-73.982738	40.761270	-73.991242	40.750562	2	0	0.019212
3	7.70	-73.987130	40.733143	-73.991567	40.758092	1	4	0.029386
4	5.30	-73.968095	40.768008	-73.956655	40.783762	1	7	0.027194
5	12.10	-74.000964	40.731630	-73.972892	40.758233	1	9	0.054675
6	7.50	-73.980002	40.751662	-73.973802	40.764842	1	20	0.019380
7	16.50	-73.951300	40.774138	-73.990095	40.751048	1	17	0.061885
8	9.00	-74.006462	40.726713	-73.993078	40.731628	1	13	0.018299
9	8.90	-73.980658	40.733873	-73.991540	40.758138	2	1	0.035147
10	5.30	-73.996335	40.737142	-73.980721	40.733559	1	7	0.019197
12	4.10	-73.991601	40.744712	-73.983081	40.744682	2	1	0.008550

In [14]:
```
df = pd.concat([df, tmp], axis=1, join='inner')
```

In [15]:
```
df = df.reset_index(drop=True)
```

In [16]:
```
df['pickup_longitude'].plot.hist(bins=100)
```

Out[16]: <matplotlib.axes._subplots.AxesSubplot at 0x1089d7940>

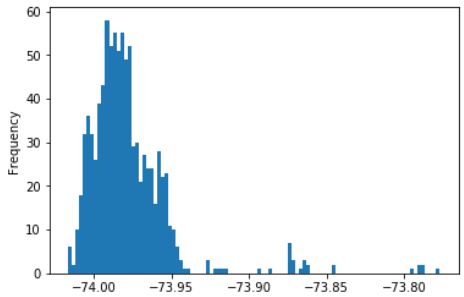

In [17]:
```
df['dropoff_longitude'].plot.hist(bins=100)
```

Out[17]: <matplotlib.axes._subplots.AxesSubplot at 0x11d0360b8>

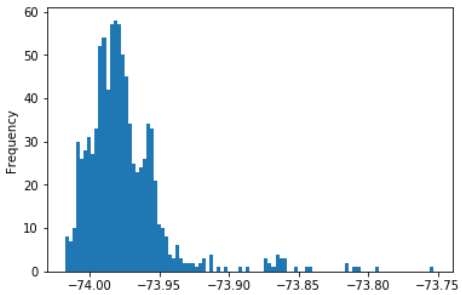

In [18]:
```
df['pickup_latitude'].plot.hist(bins=100)
```

Out[18]: <matplotlib.axes._subplots.AxesSubplot at 0x11f2110b8>

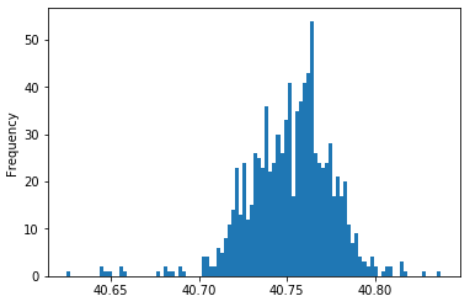

In [19]:
```
1 df['dropoff_latitude'].plot.hist(bins=100)
```

Out[19]: <matplotlib.axes._subplots.AxesSubplot at 0x11bfeea20>

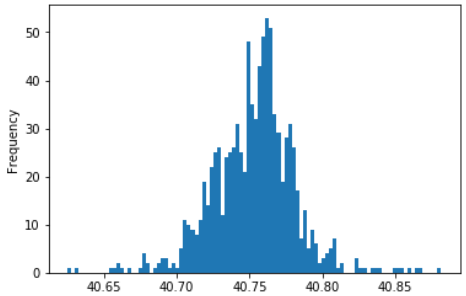

In [20]:
```
1 df['passenger_count'].value_counts().plot(kind='bar')
```

Out[20]: <matplotlib.axes._subplots.AxesSubplot at 0x11f530208>

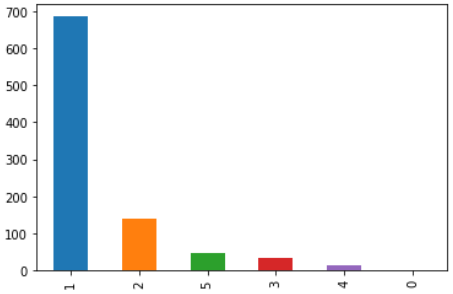

In [21]:
```
1 df['hour'].value_counts().plot(kind='bar')
```

Out[21]: <matplotlib.axes._subplots.AxesSubplot at 0x11f5ef7f0>

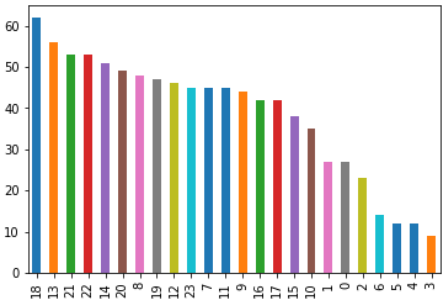

In [22]:
```
1 df['weekday'].value_counts().plot(kind='bar')
```

Out[22]: <matplotlib.axes._subplots.AxesSubplot at 0x11f3ccb70>

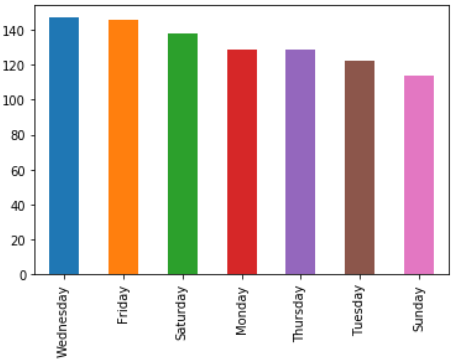

In [23]:
```
1 df['manhattan_distance'].plot.hist(bins=100)
```

Out[23]: <matplotlib.axes._subplots.AxesSubplot at 0x11f7f30f0>

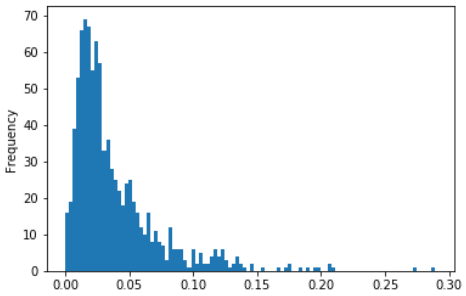

In [24]:
```
1 df['fare_amount'].plot.hist(bins=100)
```

Out[24]: <matplotlib.axes._subplots.AxesSubplot at 0x11f940b70>

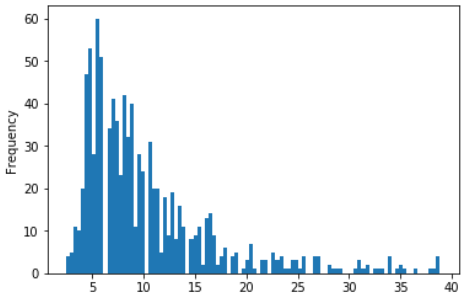

Видим, что целевая переменная имеет достаточно большой разброс.

Построим корреляционную матрицу, не забыв о том, что hour и weekday имеют категориальную природу - эти дискретные величины имеют много значений и одно значение не даст яркую корреляцию с таргетом - а картинку загрязнит, поэтому их не включаем

In [25]:
```
sns.heatmap(df.drop(['hour', 'weekday'], axis=1).corr())
```

Out[25]: <matplotlib.axes._subplots.AxesSubplot at 0x11fb63550>

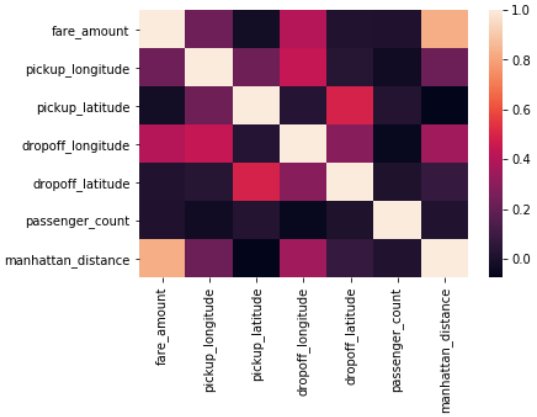

In [26]:
```
df = pd.concat([df,pd.get_dummies(df['hour'])], axis=1)
df = pd.concat([df,pd.get_dummies(df['weekday'])], axis=1)
df.drop(['hour', 'weekday'], axis=1, inplace=True)
```

Можно применить машинное обучение для аппроксимации зависимости fare_amount от набора остальных входных признаков

Выбраны метрики:

- 1 - R2 метрика. Самый лучший выбор в задачи регрессии, когда мы не знаем какой результат есть хорошо, а какой плохо
- 2 - MAE - среднее модульное отклонение
- 3 - RMSE

Выбраны модели:

- 1 - Линейная регрессия - показать результат самой примитивной по работе модель
- 2 - Random Forest Regressor - ансамблевая модель
- 2 - LightGBM - ансамблевая модель, дает лучшие показатели, на ней будет запущена кроссвалидация по сетке гиперпараметров

Будет запущен каждый эксперимент по отдельности, после каждого прогона информация сохраняется в MLFlow, данные всех экспериментов в таблице

In [36]:
```
lightgbm_parameters = {
            'subsample':[0.6, 1],
            'colsample_bytree': [0.8, 1],
            'n_estimators':[100, 300, 400],
            'n_jobs':[-1],
            'silent':[True],
            'verbosity':[0]
}
```

In [77]:
```
random_search = GridSearchCV(estimator= lightgbm.LGBMRegressor(),
                             param_grid= lightgbm_parameters,
                             scoring= 'neg_mean_squared_error',
                             cv= 3)

random_search.fit(df.loc[:, df.columns != 'fare_amount'], df['fare_amount'])
```

```
/usr/local/lib/python3.7/site-packages/sklearn/model_selection/_search.py:841: DeprecationWarning: The default of the `iid` parameter will change from True to False in version 0.22 and will be removed in 0.24. This will change numeric results when test-set sizes are unequal.
  DeprecationWarning)
```

Out[77]:
```
GridSearchCV(cv=3, error_score='raise-deprecating',
       estimator=LGBMRegressor(boosting_type='gbdt', class_weight=None, colsample_bytree=1.0,
       importance_type='split', learning_rate=0.1, max_depth=-1,
       min_child_samples=20, min_child_weight=0.001, min_split_gain=0.0,
       n_estimators=100, n_jobs=-1, num_leaves=31, objective=None,
       random_state=None, reg_alpha=0.0, reg_lambda=0.0, silent=True,
       subsample=1.0, subsample_for_bin=200000, subsample_freq=0),
       fit_params=None, iid='warn', n_jobs=None,
       param_grid={'subsample': [0.6, 1], 'colsample_bytree': [0.8, 1], 'n_estimators': [100, 300, 400], 'n_jobs': [-1], 'silent': [True], 'verbosity': [0]},
```

In [78]:
```
random_search.best_params_
```

Out[78]:
```
{'colsample_bytree': 1,
 'n_estimators': 100,
 'n_jobs': -1,
 'silent': True,
 'subsample': 0.6,
 'verbosity': 0}
```

In [61]:
```
# r2 = random_search.best_score_

# mae = -random_search.best_score_

# rmse = sqrt(-random_search.best_score_)

# r2, mae, rmse
```

In [67]:
```
import mlflow
```

In [80]:
```
with mlflow.start_run(run_name='second_good_model'):

    mlflow.log_param('model_name', 'LGBMRegressor')
    mlflow.log_param('parameters', random_search.best_params_)

    mlflow.log_metric('rmse', sqrt(-random_search.best_score_))
```

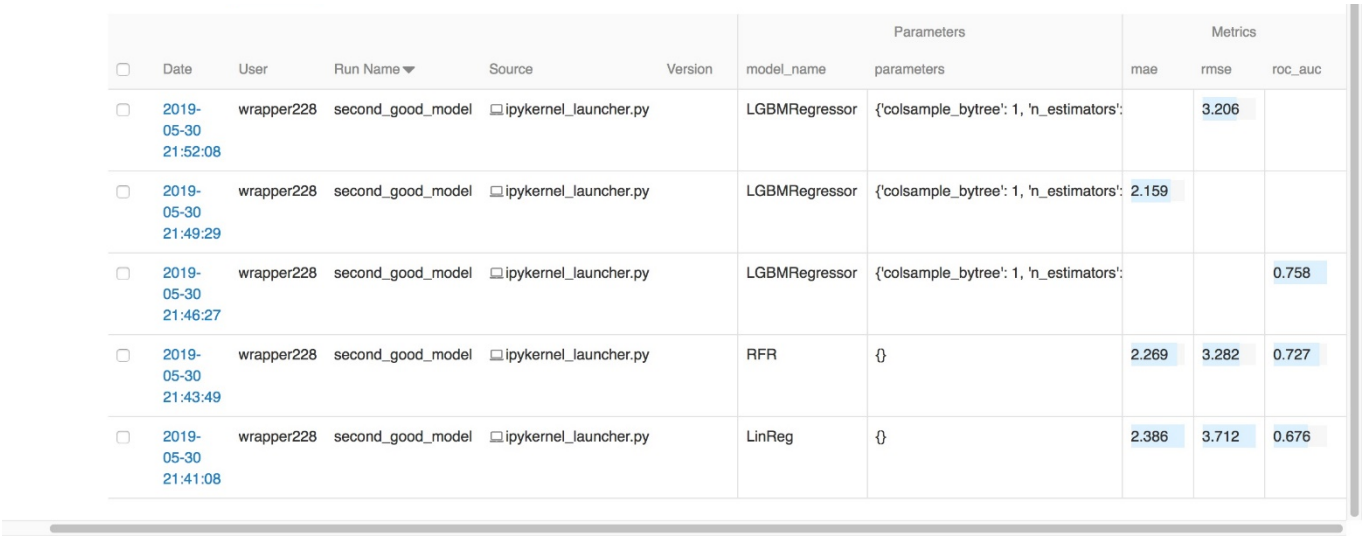

						Parameters		Metrics		
	Date	User	Run Name	Source	Version	model_name	parameters	mae	rmse	roc_auc
	2019-05-30 21:52:08	wrapper228	second_good_model	ipykernel_launcher.py		LGBMRegressor	{'colsample_bytree': 1, 'n_estimators':		3.206	
	2019-05-30 21:49:29	wrapper228	second_good_model	ipykernel_launcher.py		LGBMRegressor	{'colsample_bytree': 1, 'n_estimators':	2.159		
	2019-05-30 21:46:27	wrapper228	second_good_model	ipykernel_launcher.py		LGBMRegressor	{'colsample_bytree': 1, 'n_estimators':			0.758
	2019-05-30 21:43:49	wrapper228	second_good_model	ipykernel_launcher.py		RFR	{}	2.269	3.282	0.727
	2019-05-30 21:41:08	wrapper228	second_good_model	ipykernel_launcher.py		LinReg	{}	2.386	3.712	0.676

Заключение

В данной работе были закреплены навыки проведения разведочного анализа данных, выбора признаков для построения модели, проведения корреляционного анализа, подбора метрик, решения задачи регрессии, построения базового решения и подбора гиперпараметров, сравнены качества моделей.

Список использованной литературы

1. https://github.com/ugapanyuk/ml_course/wiki/COURSE_TMO
2. https://lightgbm.readthedocs.io/en/latest/
3. https://www.mlflow.org/
4. https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestRegressor.html
5. https://scikit-learn.org/stable/modules/generated/sklearn.metrics.mean_squared_error.html