Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное
образовательное учреждение высшего образования
«Московский государственный технический университет имени Н.Э. Баумана (национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ _Информатика и системы управления__

КАФЕДРА __Системы обработки информации и управления (ИУ5)_____

ОТЧЕТ
по лабораторной работе

«Подготовка обучающей и тестовой выборки, кросс-валидация и подбор гиперпараметров на примере метода ближайших соседей.»

ДИСЦИПЛИНА: «Технологии машинного обучения»

Выполнил: студент гр. _ИУ5-62Б_ _____ (_____Михеев Н.А.__)
(Подпись) (Ф.И.О.)

Проверил: _____ (_____Гапанюк Ю.Е.___)
(Подпись) (Ф.И.О.)

2020 г.

Лабораторная работа №4

Подготовка обучающей и тестовой выборки, кросс-вали гиперпараметров на примере метода ближайших соседе

Цель лабораторной работы

Изучение сложных способов подготовки выборки и подбора гиперпараметров на примере

Задание

1. Выберите набор данных (датасет) для решения задачи классификации или регрессии
2. С использованием метода train_test_split разделите выборку на обучающую и тестову
3. Обучите модель ближайших соседей для произвольно заданного гиперпараметра K. С подходящих для задачи метрик.
4. Постройте модель и оцените качество модели с использованием кросс-валидации.
5. Произведите подбор гиперпараметра K с использованием GridSearchCV и кросс-валид

```
import numpy as np
import pandas as pd
from typing import Dict, Tuple
from scipy import stats
from sklearn.datasets import load_breast_cancer
from sklearn.model_selection import train_test_split
from sklearn.model_selection import cross_val_score, cross_validate
from sklearn.model_selection import GridSearchCV, RandomizedSearchCV
from sklearn.neighbors import KNeighborsRegressor, KNeighborsClassifier
from sklearn.metrics import accuracy_score, balanced_accuracy_score
from sklearn.metrics import plot_confusion_matrix
from sklearn.metrics import precision_score, recall_score, f1_score, classificatio
from sklearn.metrics import confusion_matrix
from sklearn.metrics import mean_absolute_error, mean_squared_error, mean_squared_
from sklearn.metrics import roc_curve, roc_auc_score
import seaborn as sns
import matplotlib.pyplot as plt
%matplotlib inline
sns.set(style="ticks")
```

Подготовка данных и построение базовых моделей для оценки

```
breast_cancer = load_breast_cancer()
```

```
# Наименования признаков
breast_cancer.feature_names
```

```
array(['mean radius', 'mean texture', 'mean perimeter', 'mean area',
       'mean smoothness', 'mean compactness', 'mean concavity',
       'mean concave points', 'mean symmetry', 'mean fractal dimension',
       'radius error', 'texture error', 'perimeter error', 'area error',
       'smoothness error', 'compactness error', 'concavity error',
       'concave points error', 'symmetry error',
       'fractal dimension error', 'worst radius', 'worst texture',
       'worst perimeter', 'worst area', 'worst smoothness',
       'worst compactness', 'worst concavity', 'worst concave points',
       'worst symmetry', 'worst fractal dimension'], dtype='<U23')
```

```
type(breast_cancer.data)
```

```
numpy.ndarray
```

```
data = pd.DataFrame(data= np.c_[breast_cancer['data'], breast_cancer['target']],
                    columns= breast_cancer['feature_names'].tolist() + ['target']
```

```
data.head()
```

	mean radius	mean texture	mean perimeter	mean area	mean smoothness	mean compactness	mean concavity	me conca poin
0	17.99	10.38	122.80	1001.0	0.11840	0.27760	0.3001	0.147
1	20.57	17.77	132.90	1326.0	0.08474	0.07864	0.0869	0.070
2	19.69	21.25	130.00	1203.0	0.10960	0.15990	0.1974	0.127
3	11.42	20.38	77.58	386.1	0.14250	0.28390	0.2414	0.105
4	20.29	14.34	135.10	1297.0	0.10030	0.13280	0.1980	0.104

5 rows × 31 columns

Разделение выборки на обучающую и тестовую

```
X_train, X_test, Y_train, Y_test = train_test_split(
    breast_cancer.data, breast_cancer.target, test_size=0.3, random_state=1)
```

```
# Размер обучающей выборки
X_train.shape, Y_train.shape
```

```
((398, 30), (398,))
```

```
# Размер тестовой выборки
X_test.shape, Y_test.shape
```

```
((171, 30), (171,))
```

Обучение модели ближайших соседей для заданного гиперпара

```
# 3 ближайших соседа
# Метрика accuracy вычисляет процент (долю в диапазоне от 0 до 1) правильно опреде
cl1_1 = KNeighborsClassifier(n_neighbors=3)
cl1_1.fit(X_train, Y_train)
target1_0 = cl1_1.predict(X_train)
target1_1 = cl1_1.predict(X_test)
accuracy_score(Y_train, target1_0), accuracy_score(Y_test, target1_1)
```

```
(0.9472361809045227, 0.9239766081871345)
```

```
# 8 ближайших соседей
# Метрика accuracy вычисляет процент (долю в диапазоне от 0 до 1) правильно опреде
cl1_2 = KNeighborsClassifier(n_neighbors=8)
cl1_2.fit(X_train, Y_train)
target2_0 = cl1_2.predict(X_train)
target2_1 = cl1_2.predict(X_test)
accuracy_score(Y_train, target2_0), accuracy_score(Y_test, target2_1)
```

```
(0.9321608040201005, 0.9415204678362573)
```

Построение модели с использованием кросс-валидации

```
scores = cross_val_score(KNeighborsClassifier(n_neighbors=3),
                         breast_cancer.data, breast_cancer.target, cv=3)
```

```
# Значение метрики accuracy для 3 фолдов
scores
```

```
array([0.89473684, 0.95263158, 0.91534392])
```

```
# Усредненное значение метрики accuracy для 3 фолдов
np.mean(scores)
```

```
0.9209041121321823
```

```
# использование метрики precision
scores = cross_val_score(KNeighborsClassifier(n_neighbors=3),
                         breast_cancer.data, breast_cancer.target, cv=3,
                        scoring='precision_weighted')
scores, np.mean(scores)
```

```
(array([0.89654273, 0.9533197 , 0.91504168]), 0.9216347037536606)
```

```
# функция cross_validate позволяет использовать для оценки несколько метрик
scoring = {'precision': 'precision_weighted',
           'jaccard': 'jaccard_weighted',
           'f1': 'f1_weighted'}

scores = cross_validate(KNeighborsClassifier(n_neighbors=3),
                        breast_cancer.data, breast_cancer.target, scoring=scoring,
                        cv=3, return_train_score=True)
scores
```

```
{'fit_time': array([0., 0., 0.]),
 'score_time': array([0.03152204, 0.01564574, 0.03126574]),
 'test_precision': array([0.89654273, 0.9533197 , 0.91504168]),
 'train_precision': array([0.9585625 , 0.95775754, 0.9533197 ]),
 'test_jaccard': array([0.80818208, 0.9091925 , 0.84433622]),
 'train_jaccard': array([0.91863329, 0.91899267, 0.9091925 ]),
 'test_f1': array([0.89287184, 0.95225452, 0.9150832 ]),
 'train_f1': array([0.95744193, 0.95765583, 0.95225452])}
```

Подбор гиперпараметра K с использованием GridSearchCV и кр

```
n_range = np.array(range(5,55,5))
tuned_parameters = [{'n_neighbors': n_range}]
tuned_parameters
```

```
[{'n_neighbors': array([ 5, 10, 15, 20, 25, 30, 35, 40, 45, 50])}]
```

```
%%time
clf_gs = GridSearchCV(KNeighborsClassifier(), tuned_parameters, cv=5, scoring='acc
clf_gs.fit(X_train, Y_train)
```

```
Wall time: 686 ms
GridSearchCV(cv=5, error_score=nan,
             estimator=KNeighborsClassifier(algorithm='auto', leaf_size=30,
                                            metric='minkowski',
                                            metric_params=None, n_jobs=None,
                                            n_neighbors=5, p=2,
                                            weights='uniform'),
             iid='deprecated', n_jobs=None,
             param_grid=[{'n_neighbors': array([ 5, 10, 15, 20, 25, 30, 35, 40
             pre_dispatch='2*n_jobs', refit=True, return_train_score=False,
             scoring='accuracy', verbose=0)
```

```
clf_gs.cv_results_
```

```
{'mean_fit_time': array([0.00231314, 0.00184054, 0.00312042, 0.01037116, 0.003
        0.0062571 , 0.0031249 , 0.00624986, 0.        , 0.        ]),
 'std_fit_time': array([0.00079557, 0.00119532, 0.00624084, 0.00866432, 0.0063
        0.00766336, 0.00624981, 0.00765448, 0.        , 0.        ]),
 'mean_score_time': array([0.01362453, 0.00723748, 0.01249657, 0.01564269, 0.0
        0.0062501 , 0.00624762, 0.00312676, 0.00937333, 0.00625267]),
 'std_score_time': array([0.01524153, 0.00502408, 0.00624831, 0.0098877 , 0.01
```

```
        0.00765478, 0.00765174, 0.00625353, 0.00765331, 0.00765793]),
 'param_n_neighbors': masked_array(data=[5, 10, 15, 20, 25, 30, 35, 40, 45, 50
              mask=[False, False, False, False, False, False, False, False,
                    False, False],
        fill_value='?',
             dtype=object),
 'params': [{'n_neighbors': 5},
  {'n_neighbors': 10},
  {'n_neighbors': 15},
  {'n_neighbors': 20},
  {'n_neighbors': 25},
  {'n_neighbors': 30},
  {'n_neighbors': 35},
  {'n_neighbors': 40},
  {'n_neighbors': 45},
  {'n_neighbors': 50}],
 'split0_test_score': array([0.8625, 0.925 , 0.9   , 0.9375, 0.9375, 0.9   , 0
        0.8875, 0.9   ]),
 'split1_test_score': array([0.875 , 0.8875, 0.9125, 0.9   , 0.9125, 0.9125, 0
        0.9125, 0.9125]),
 'split2_test_score': array([0.9125, 0.925 , 0.9625, 0.9625, 0.9625, 0.9625, 0
        0.9625, 0.9625]),
 'split3_test_score': array([0.96202532, 0.96202532, 0.94936709, 0.93670886, 0
        0.93670886, 0.94936709, 0.94936709, 0.93670886, 0.93670886]),
 'split4_test_score': array([0.91139241, 0.91139241, 0.88607595, 0.89873418, 0
        0.87341772, 0.87341772, 0.86075949, 0.86075949, 0.87341772]),
 'mean_test_score': array([0.90468354, 0.92218354, 0.92208861, 0.92708861, 0.9
        0.91702532, 0.92205696, 0.91452532, 0.91199367, 0.91702532]),
 'std test score': array([0.0347987 , 0.02417697, 0.02916832, 0.02446499, 0.03
```

```
# Лучшая модель
clf_gs.best_estimator_
```

```
KNeighborsClassifier(algorithm='auto', leaf_size=30, metric='minkowski',
                     metric_params=None, n_jobs=None, n_neighbors=20, p=2,
                     weights='uniform')
```

```
# Лучшее значение метрики
clf_gs.best_score_
```

```
0.9270886075949367
```

```
# Лучшее значение параметров
clf_gs.best_params_
```

```
{'n_neighbors': 20}
```

```
# Изменение качества на тестовой выборке в зависимости от K-соседей

plt.plot(n_range, clf_gs.cv_results_['mean_test_score'])
```

```
[<matplotlib.lines.Line2D at 0x9c86d50>]
```

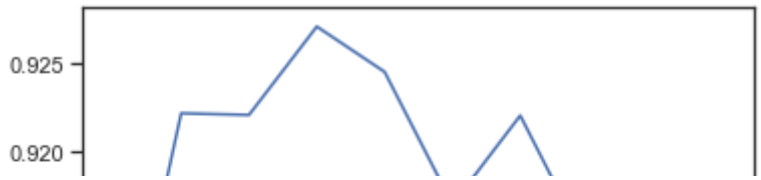

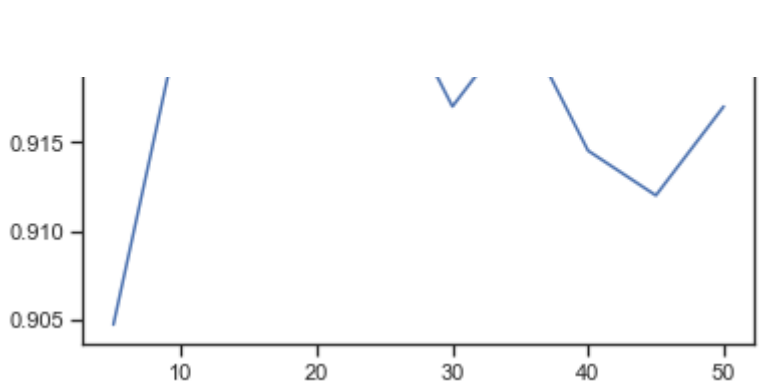

Оптимальный гиперпараметр K = 20